# Сравнение двух случайных выборок (нахождение оценок параметров распределения, проверка статистических гипотез)

# Математические выкладки

# Точечные оценки параметров распределения

Распределение случайной величины X характеризуется рядом *параметров* (математическое ожидание, дисперсия и т.д.). Эти параметры называют *параметрами генеральной совокупности*. Важной задачей математической статистики является нахождение по случайной выборке приближенных значений каждого из параметров, называемых *точечными оценками параметров*, или просто *оценками*. Таким образом, *оценкой параметра*  $\beta$  называется функция  $f(X_1, X_2, ..., X_n)$  от случайной выборки, значение которой принимается в качестве приближенного для данного параметра и обозначается  $\beta$ :

$$\beta \approx \widetilde{\beta} = f(X_1, X_2, \dots, X_n). \tag{3.1}$$

Пусть задана повторная случайная выборка  $X_1, X_2, ..., X_n$ . За оценку математического ожидания а принимается среднее арифметическое элементов выборки:

$$\overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_i \tag{3.2}$$

Oценкой дисперсии  $\sigma^2$  при неизвестном математическом ожидании является величина  $S^2$ , которую называют эмпирической дисперсией:

$$S^{2} = \frac{1}{n-1} \sum_{i=1}^{n} (X_{i} - \overline{X})^{2}$$
(3.3)

Оценкой среднего квадратического отклонения о при этом является, соответственно, величина

$$S = \sqrt{S^2} \tag{3.4}$$

Для практических расчетов формулу (3.3) целесообразно преобразовать к следующему виду:

$$S^{2} = \frac{1}{n-1} \left( \sum_{i=1}^{n} X_{i}^{2} - n \overline{X}^{2} \right)$$
 (3.5)

Вычисление среднего значения  $\overline{X}$  и оценки дисперсии  $S^2$  упрощается, если отсчет значений  $X_i$  вести от подходящим образом выбранного начала отсчета C и в подходящем масштабе, т.е. сделать линейную замену (кодирование):

$$X_i = C + hU_i \ (i = 1, 2, ..., n).$$
 (3.6)

При такой замене формулы (3.2), (3.3), (3.4) принимают следующий вид:

$$\bar{X} = C + h\bar{U}; \qquad \bar{U} = \frac{1}{n} \sum_{i=1}^{n} U_i. \tag{3.7}$$

$$S^{2} = \frac{h^{2}}{n-1} \sum_{i=1}^{n} (U_{i} - \overline{U})^{2} = \frac{h^{2}}{n-1} \left( \sum_{i=1}^{n} U_{i}^{2} - n \overline{U}^{2} \right).$$
 (3.8)

Для контроля правильности вычислений весь расчет следует повторить при другом начале отсчета C: результаты должны совпадать с точностью до величины возможных ошибок округления.

# Доверительные интервалы параметров нормального распределения

 $\mathcal{A}$ оверительным интервалом параметра eta называется интервал со случайными границами ( $\widetilde{eta}$  –  $\epsilon_1;\ \widetilde{\beta}+\epsilon_2),$  который накрывает истинное значение параметра  $\beta$  с заданной вероятностью P,которая называется доверительной вероятностью. Величина  $\alpha = 1 - P$  называется уровнем значимости. При этом обычно требуют, чтобы вероятности выхода за границы доверительного интервала в обе стороны были равны между собой, а именно:  $P(\beta < \widetilde{\beta} - \varepsilon_1) = P(\beta > \widetilde{\beta} + \varepsilon_2) = (1 - P)/2 = \alpha/2.$ 

Это дополнительное требование обеспечивает единственность решения задачи. Пусть задана повторная случайная выборка  $X_1, X_2, ..., X_n$  из нормальной генеральной совокупности. Это означает, что результаты эксперимента независимы и подчиняются нормальному закону распределения с одинаковыми параметрами  $X_i \sim N(a; \sigma)$ .

C вероятностью P математическое ожидание принадлежит интервалу

$$a \in (\overline{X} - \varepsilon, \overline{X} + \varepsilon);$$
 (3.9)

$$\varepsilon = t_{1-\alpha/2}(k) S/\sqrt{n}$$
(3.10)

где  $\overline{X}$  – оценка математического ожидания (3.2);  $S = \sqrt{S^2}$  – оценка среднего квадратического отклонения  $\sigma$  (3.4);

 $t_{1-\alpha/2}(k)$  – квантиль распределения Стьюдента с k степенями свободы; n – объем выборки; k – число степеней свободы при вычислении оценки S.

Часто доверительный интервал для математического ожидания записывают символически:

$$\alpha = \overline{Y} \pm \varepsilon. \tag{3.11}$$

Доверительный интервал для среднего квадратического отклонения о при доверительной вероятности  $P = 1 - \alpha$  имеет следующий вид:

$$S\sqrt{\frac{k}{\chi_{1-\alpha/2}^2(k)}} < \sigma < S\sqrt{\frac{k}{\chi_{\alpha/2}^2(k)}},$$
 (3.12)

где S — оценка среднего квадратического отклонения  $\sigma$  (1.6) при неизвестном математическом ожидании;  $\chi_P^2(k)$  – квантиль распределения Пирсона с k степенями свободы; k – число степеней свободы оценки S.

### Проверка статистических гипотез

Пусть X – наблюдаемая случайная величина. Статистической гипотезой H называется предположение относительно параметров или вида распределения случайной величины X. Проверяемая гипотеза называется *нуль-гипотезой* и обозначается  $H_0$ . При постановке нульгипотезы сразу ставится альтернативная гипотеза  $H_1$ , т.е. то предположение, которое следует принять, если нуль-гипотеза будет отвергнута.

Правило, позволяющее принять или отвергнуть гипотезу  $H_0$  – некоторая функция результатов эксперимента  $Q(X_1, X_2, ..., X_n)$ , распределение которой вполне определено при условии истинности гипотезы  $H_0$ .

Пусть заданы две независимые выборки из двух нормальных генеральных совокупностей. Первая выборка имеет объем  $n_1$ , элементы выборки  $X_1^{(1)} \sim N(a;\sigma_1)$ ; вторая – объем  $n_2$ , элементы выборки  $X_1^{(2)} \sim N(a;\sigma_1)$ . Необходимо проверить гипотезу о равенстве дисперсий этих двух генеральных совокупностей, т.е.  $H_0$ :  $\sigma_1^2 = \sigma_1^2$ . Математические ожидания a и a 1 2

неизвестны.

неизвестны. В этом случае по каждой выборке находят несмещенные оценки дисперсий  $S^2$  и  $S^2$  с числами  $S^2$  1 и  $S^2$  2 с числами  $S^2$  2 и  $S^2$  2

степеней свободы  $k_1 = n_1 - 1$  и  $k_2 = n_2 - 1$  соответственно. Гипотезу проверяют по критерию Фишера, функция критерия

 $F = S_1^2 / S_2^2$ (3.13)

имеет F-распределение Фишера с  $k_1$  и  $k_2$  степенями свободы, т.е.  $F = F(k_1, k_2)$ .

Если альтернативная гипотеза  $H_1$ :  $\sigma_1^2 \neq \sigma_2^2$ , то критерий Фишера рассчитывается как отношение большей по величине оценки дисперсии к меньшей:

$$F = (S_{\text{бол}})^2 / (S_{\text{MeH}})^2 > 1. \tag{3.14}$$

Гипотеза принимается при выполнении неравенства

$$F < F_{1-\alpha/2}(k_{S_{60\Pi}}, k_{S_{MOH}}),$$
 (3.15)

в противоположном случае гипотеза отвергается. Здесь  $k_{\mathrm{S}_{\mathrm{бол}}}$  – число степеней свободы большей оценки дисперсии;  $k_{\mathbf{S}_{\mathrm{мен}}}$  – число степеней свободы меньшей оценки дисперсии. Если гипотеза о равенстве дисперсий принимается, то за оценку общей σ может быть взята  $S = \sqrt{S_{\infty}^2}$ , полученная по формуле для сводной оценки дисперсии:

$$S_{\infty}^{2} = \frac{k_{1}S_{1}^{2} + k_{2}S_{2}^{2}}{k_{1} + k_{2}}; \quad k_{j} = n_{j} - 1; \quad j = 1, 2,$$
(3.16)

 $S_{\rm cs}^2 = \frac{k_{\rm l}S_1^2 + k_2S_2^2}{k_1 + k_2}; \quad k_j = n_j - 1; \quad j = {\rm l,\ 2},$  где  $S_1^{-2},\ S_2^{-2}$  – несмещенные оценки дисперсии первой и второй выборок соответственно.

Пусть заданы две независимые выборки из двух нормальных генеральных совокупностей.

Первая выборка имеет объем  $n_1$ , элементы выборки  $X_1^{(1)} \sim N(a_1; \sigma_1)$ ; вторая — объем  $n_2$  элементы выборки  $X_1^{(2)} \sim N(a_1; \sigma_1)$ . Математические ожидания  $a_1$  и  $a_2$  неизвестны.

Проверяем гипотезу о равенстве математических ожиданий этих двух генеральных совокупностей, т.е.  $H_0$ :  $a_1 = a_2$ . По каждой выборке находим оценки математических ожиданий

 $\overline{\chi}_1$  и  $\overline{\chi}_2$ . При этом дисперсии  $\sigma_1^2$  и  $\sigma_2^2$  неизвестны, но гипотеза о равенстве дисперсий принимается;  $S_1^2$  и  $S_2^2$  — несмещенные оценки дисперсий первой и второй выборок. Находим

сводную оценку дисперсии (3.16).

Гипотеза проверяется по критерию Стьюдента, функция критерия

$$t = \frac{\overline{X_1} - \overline{X_2}}{S_{cx} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$
(3.17)

имеет t-распределение Стьюдента с  $k_{CB}$  степенями свободы, т.е.  $t=t(k_{CB}); \quad k_{CB}=k_1+k_2-k_2$ число степеней свободы при вычислении оценки  $\mathcal{S}_{\text{CB}} = \sqrt{\mathcal{S}_{\text{CB}}^2}$ . При альтернативной гипотезе  $H_1$ :

 $a_1 \neq a_2$ , гипотеза принимается при выполнении неравенства

$$|t| < t_{1-\alpha/2}(k_{CB}),$$
 (3.18)

в противоположном случае гипотеза отвергается.

Если гипотеза о равенстве математических ожиданий принимается, то за оценку общего математического ожидания может быть взята сводная оценка математического ожидания, которая определяется как средняя по обеим выборкам:

$$\overline{X}_{CB} = \frac{n_1 \overline{X}_1 + n_2 \overline{X}_2}{n_1 + n_2} \,. \tag{3.19}$$

Доверительный интервал для математического ожидания при этом можно пересчитать, заменив в формулах (3.10) – (3.11)  $\overline{\chi}$  на  $\overline{\chi}_{CB}$ ; S на  $S_{CB}$ ; k на  $k_{CB} = k_1 + k_2$ , n на  $n_1 + n_2$ .

# Проверка гипотезы о виде распределения генеральной совокупности

Если распределение случайной величины X не известно, можно рассмотреть гипотезу о том, что X имеет функцию распределения F(x). Критерии значимости для проверки таких гипотез называются *критериями согласия*.

Пусть  $X_1, X_2, ..., X_n$  – выборка наблюдений случайной величины X. Проверяется гипотеза  $H_0$ , утверждающая, что X имеет функцию распределения F(x).

Проверку гипотезы  $H_0$  при помощи критерия  $\chi^2$  проводят следующим образом. По выборке находят оценки неизвестных параметров предполагаемого закона распределения случайной величины X. Область возможных значений случайной величины X разбивают на l интервалов. Подсчитывают числа  $n_i$  попаданий результатов экспериментов в каждый i-й интервал. Используя предполагаемый закон распределения случайной величины X, находят вероятности  $p_i$  того, что значение X принадлежит i-му интервалу. Затем сравнивают полученные частоты  $n_i$  /n с вероятностями  $p_i$ . Критерий согласия Пирсона требует принятия гипотезы о пригодности проверяемого распределения с уровнем значимости  $\alpha$ , если значение  $\alpha$  взвешенной суммы  $\alpha$  квадратов отклонений

$$\chi^{2} = n \sum_{i=1}^{l} \frac{(n_{i} / n - p_{i})^{2}}{p_{i}} = \sum_{i=1}^{l} \frac{(n_{i} - np_{i})^{2}}{np_{i}}$$
(3.20)

меньше квантиля распределения  $\chi^2$ -распределения с k=l-1 степенями свободы, т.е.  $\chi^2 < (\chi_{1-\alpha})^2(k)$ ,

в противоположном случае эта гипотеза отвергается, как противоречащая результатам эксперимента. Если при этом некоторые параметры распределения оценивают по результатам той же выборки, то квантиль  $\chi^2$ -распределения следует брать для k=l-1-m степеней свободы, где m – число оцениваемых параметров.

### Построение гистограммы (эмпирической функции распределения)

Для наглядного представления о выборке часто используют график, называемый  $\mathit{гистограммой}$ . Для построения гистограммы интервал, содержащий все элементы выборки, разбивают на l непересекающихся интервалов (как правило, равной длины). Подсчитывают числа  $n_i$  попаданий результатов экспериментов в каждый i-й интервал и строят столбиковую диаграмму, откладывая по оси ординат значения средней плотности  $n_i$  /( $nh_i$ ), где  $h_i$  — длина i-го интервала. Площадь каждого столбика равна  $n_i$ /n, что соответствует относительной частоте попадания элементов выборки в i-й интервал. Площадь под всей ступенчатой фигурой равна единице.

При увеличении объема выборки и уменьшении интервалов группировки гистограмма приближается к функции плотности генеральной совокупности. Гистограмма является эмпирической функцией плотности, она дает приближенную функцию плотности генеральной совокупности (ее оценку) по случайной выборке.